

final

FINAL 데이터셋 설명 문서

1. 개요

분석 단위: 동대문구 아파트 단지 317개 (100세대 기준 K-apt 필터를 버리고, 실거래가 데이터에 실제로 존재하는 모든 단지로 재구성)

시간 범위: 2019년 1분기 ~ 2025년 4분기 (28개 분기, 3/6/9/12월 기준)

행 구조: `단지 × 분기` 패널 데이터, 총 **8,876행 × 48개 컬럼**

핵심 목적: 각 단지·분기별로 입지 특성(X)과 실거래가(Y)를 결합해, 나중에 GWR(공간적 이질성 증명)과 LASSO(변수 선택 + 예측)로 "동일 LTV 규제 하에서도 단지별 리스크가 다르다"는 가설을 검증하기 위한 최종 분석용 테이블

2. 마스터 단지 리스트가 만들어진 과정

- 처음엔 K-apt(공동주택관리정보시스템) 기준 "100세대 이상" 125개 단지로 시작
- 이후 "실거래가 데이터에 실제로 존재하는 단지 기준"으로 전환 → 실거래가 원본 (`master_19_25_cleaning.csv`)의 고유 `complex_id` 316개로 재구성
- 이 과정에서 **휘경주공1단지/주공2단지**가 실거래가 시스템상 같은 `complex_id` (같은 지번)를 공유하지만, 실제로는 평균 전용면적(93.9m^2 vs 48.5m^2)이 다른 별개 건물이라는 게 발견되어 **317개로 최종 확정** (`apt_name` 컬럼으로 구분)

3. 컬럼 설명 (48개 전체)

3-1. 식별자 / 위치 정보

컬럼명	설명
<code>complex_id</code>	단지 고유 ID (실거래가 원본 데이터 기준 ID)
<code>apt_name</code>	단지명 (휘경주공1/2단지는 <code>apt_name</code> 으로 구분됨)
<code>dong</code>	법정동 (예: 장안동, 답십리동)
<code>jibun</code>	지번

컬럼명	설명
lat , lon	위도/경도 좌표
admin_dong	행정동 (법정동과 다름 — 아래 3-5 참고)
yyyymm	연월 (분기말 기준: 3/6/9/12월, 예: 202412 = 2024년 4분기)

3-2. 종속변수(Y) — 실거래가

컬럼명	설명
avg_price_per_m2	해당 단지·분기의 평균 면적당 단가(만원/㎡). 결측 5,407개(전체의 약 61%) — 그 분기에 실제 거래가 없었던 정상적 결측
deal_count	해당 단지·분기의 거래건수 (평균단가의 신뢰도 체크용). 결측 패턴은 avg_price_per_m2 와 동일

3-3. 상권 (2가지 버전 병존)

컬럼명	설명
commercial_index	엔트로피 가중치 기반 상권지수. "이 업종이 단지 간 변별력이 얼마나 큰가"만 반영 (가격과의 인과관계 없음, 항상 양수). 결측 0개
commercial_index_lasso19	LASSO 회귀 기반 상권지수(컬럼명은 유지되었으나 내용은 최신 버전으로 갱신됨 — 아래 참고). 결측 0개

상권지수 만든 과정 (요약)

1. 소상공인시장진흥공단 상가 데이터(2019Q1~2025Q4 분기별, 28개 분기 전체 확보 완료)에서 동대문구만 필터
2. 카테고리 매핑: 보건의료·교육·음식·예술스포츠·수리개인·시설관리임대는 대분류 유지, 소매·과학기술은 중분류로 세분화, 부동산·숙박 제외
3. 전체기간(28분기) 분기당 평균 표본이 50개 미만인 중분류(연료소매, 애완동물용품소매, 법무관련, 가구소매, 담배소매, 수의, 기타전문과학, 모터사이클소매, 음료소매, 시장조사)는 대분류로 병합 → **최종 30개 카테고리**
4. 각 단지 중심점 반경 500m 버퍼 내 카테고리별 점포 수 집계
5. commercial_index : 30개 카테고리를 엔트로피 가중치로 압축
6. commercial_index_lasso19 : 단지 고정효과(단지별 평균가) 제거한 가격편차를 종속변수로, 30개 카테고리 비율을 LASSO 회귀에 투입

- 1차 시도(일반 K-fold 교차검증): 표본 수에 따라 alpha가 불안정하게 흔들리는 문제 발견(19개 ↔ 28개 선택 오락가락)
- 원인: 같은 단지의 여러 분기가 학습/검증 폴드에 무작위로 섞여 들어가면서 자기상관으로 인한 정보 누수 발생
- 개선: **GroupKFold** 로 **단지 단위 완전 분리** 교차검증 적용 → $\alpha=0.91$, $R^2=0.132$, 30개 중 **25개 카테고리 선택**, 계수(부호 포함) 재정규화 가중합

3-4. 학군

컬럼명	설명
school_pc1	초등학교군 리스크 지수 (PCA 1주성분). 연도별 시계열 — 값이 클수록 학군 리스크 낮음(안정적). 결측 0개

만든 과정

- 원천 지표: 학교폭력 심의건수(2024~2026 고정값, 연도별 분해 불가) + 전출입비율(2019~2025 연도별 실측치)
- 학교폭력·전출입 두 지표를 반전(낮을수록 좋음 → 높을수록 좋음)한 뒤, **133개 관측치 (19개 학교×7개년) 전체를 한 번에 PCA 학습**해서 로딩(가중치)을 고정 → 매년 값에 동일 가중치 적용 (엔트로피 상권지수랑 같은 원칙: "가중치는 한 번만 고정, 값은 시간에 따라 변화")
- 학구 배정: 초등학교 통학구역 shapefile(한국교육시설안전원)과 각 단지 좌표를 공간 조인. 공동학구(두 학교 공유 구역)는 두 학교 PC1 평균 사용
- 예외: 신묵초(종량구 소재, 이문동 2개 단지 배정) — 행정구역과 무관하게 실제 통학구역 기준으로 배정한 결과이며, 학교폭력 통계는 팀에서 별도 확보한 값 사용

3-5. 인구

컬럼명	설명
pop_growth_mom	행정동 기준 전월 대비 등록인구 증가율(%), 소수점 3자리 반올림. 결측 0개
population	행정동 기준 등록인구 수. 결측 0개
living_population	행정동 기준 생활인구 (등록인구 + 유동인구 개념), 24시간 평균을 분기말월 기준으로 집계. 결측 317개 (2025년 9월 분기, 아래 참고)

만든 과정

- `pop_growth_mom` / `population`: 주민등록인구 월간 통계(2018.12~2025.12) → 분기말월 (3/6/9/12) 값 사용
- `living_population`: 서울시 생활인구 시간대별 원본(258MB, 일별×시간대별) → 일별 24시간 평균 → 분기말월 일평균으로 집계
- **행정동 매핑 방법**: 법정동(예: 장안동)이 행정동 2개(장안제1동/2동)로 나뉘는 문제를, 상권 데이터에 이미 태깅된 **행정동명** 속성을 활용해 **각 단지의 최근접 상가의 행정동명**을 가져오는 방식으로 해결 (평균 거리 30m 이내, 별도 행정동 경계 shapefile 없이 해결)

3-6. 자연지형(경사도) — 4개 반경 × 6개 통계 = 24개 컬럼

컬럼 패턴	설명
<code>slope_mean_{100/150/200/300}m</code>	반경 내 평균 경사도
<code>slope_median_{100/150/200/300}m</code>	반경 내 중위 경사도
<code>slope_stdev_{100/150/200/300}m</code>	반경 내 경사도 표준편차
<code>slope_min_{100/150/200/300}m</code>	반경 내 최소 경사도
<code>slope_max_{100/150/200/300}m</code>	반경 내 최대 경사도
<code>slope_range_{100/150/200/300}m</code>	반경 내 경사도 범위(최대-최소)

- DEM(수치표고모델) 기반, 시간에 안 변하는 정적 변수 (전 분기 동일값). 결측 0개
- **주의**: 4개 반경끼리 상관관계가 매우 높을 가능성 → 모델링 시 반경 하나만 선택하거나 PCA 압축 권장

3-7. 교통

컬럼명	설명
<code>station_name</code>	최근접 지하철역명. 결측 5,936개 — 원본 데이터 자체의 정보성 컬럼 결측 (아래 수치형 컬럼들은 영향 없음)
<code>straight_dist_m</code>	최근접역까지 직선거리(m). 결측 0개
<code>walk_dist_m</code>	최근접역까지 추정 도보거리(m). 결측 0개
<code>walk_time_min</code>	최근접역까지 추정 도보시간(분). 결측 0개
<code>avg_daily_ridership</code>	최근접역의 일평균 승하차인원. 결측 0개
<code>station_zone</code>	역세권 구간 (초역세권 5분 이내 / 역세권 5~10분 / 준역세권 10~15분 / 비역세권 15분 초과). 결측 0개

- 정적 변수 (역 위치는 안 변하므로 전 분기 동일값)

3-8. 건물 특성

컬럼명	설명
<code>buildYear</code>	준공연도. 결측 0개
<code>building_age</code>	건축연령 (2026년 기준 계산). 결측 0개

- **모델 해석 시 필수 통제변수:** 신축단지 입주 초기엔 학군 전출입비율이 일시적으로 급증하는 등, 다른 변수 해석을 왜곡할 수 있어서 항상 같이 통제해야 함

4. 결측 현황 정리 (정확한 최종 수치)

컬럼	결측 개수	비율	원인
<code>avg_price_per_m2</code>	5,407	61.0%	그 분기에 실제 거래가 없었던 정상적 결측
<code>deal_count</code>	5,407	61.0%	위와 동일
<code>station_name</code>	5,936	66.9%	원본 데이터 자체의 역명 정보 결측 (거리·시간 등 수치형 컬럼은 정상)
<code>living_population</code>	317	3.6%	서울시 생활인구 원본 데이터에 2025년 9월(202509) 데이터가 통째로 누락되어 있음 (317 = 그 분기 전체 단지 수)
그 외 모든 컬럼	0	0%	상권지수 2종, 학군, 경사도 24개, 교통 수치형 5개, 인구증가율/인구수, 건물특성 등 핵심 X변수는 전부 결측 없이 완비됨

이전 버전(202503 분기 좌표 오염 이슈)은 카카오맵 재지오코딩으로 완전히 해결되어, 현재 상권지수 2종 모두 28개 분기 전체 결측 0개 상태입니다.

5. 두 상권지수 중 어느 걸 쓸지

- `commercial_index` (엔트로피): 방법론적으로 "단지 간 변별력"만 반영, 가격과의 인과관계 검증 안 됨
- `commercial_index_lasso19` (LASSO, GroupKFold 기반 최신 버전): 단지 고정효과를 제거한 가격편차와의 관계를 반영. 단지 단위 교차검증 기준 $R^2=0.132$ (상권 변수 단독으로 가격변동의 약 13.2% 설명)

- **권장:** 종합 LASSO/GWR 모델에 두 버전을 각각 넣어보고 최종 예측력을 비교해서 채택하는 방식으로 진행
-

6. 다음 단계

1. 다중공선성 체크 (특히 경사도 4개 반경, 교통-상권-생활인구 간 상관관계)
2. GWR: 단지별 국지 회귀계수로 "행정구역 일괄 규제"의 한계" 통계적 증명
3. LASSO/ElasticNet: 전체 변수(상권+학군+인구+경사도+교통+건물특성) 종합 투입, 자동 변수선택 + 리스크 스코어 산출 (교차검증은 단지 단위 GroupKFold 원칙 유지 권장)
4. 리스크 스코어 → LTV 매핑 로직 설계